

ANÁLISIS EXPLORATORIO DE DATOS



Andrea Zarahi Rubio Quezada A01645257

Erik Abraham Jajan Diaz A01644648

Conjunto REHAB · Datos procesados de ejercicios · 4,257 muestras · 15 movimientos

1. Objetivo y alcance

El objetivo del análisis exploratorio es caracterizar las señales resumidas de los sensores y determinar qué propiedades pueden contribuir a diferenciar los movimientos de rehabilitación. El análisis cubre estructura y balance, estadística descriptiva, distribuciones univariadas, relaciones multivariadas, correlaciones, interacciones y calidad de datos. El movimiento 014 se excluyó debido al problema identificado en sus archivos, por lo que se analizaron 15 clases.

2. Entendimiento de los datos

2.1 Movimientos

Código	Movimiento
000	Apretón de manos Bobath
001	Flexión y extensión Bobath
002	Flexión y extensión hacia adelante Bobath
003	Rotación anterior y posterior Bobath
004	Flexión del codo y compresión de la muñeca
005	Flexión y extensión de la muñeca
006	Entrenamiento dedo con dedo
007	Agarre de una pelota
008	Rotación interna y externa del hombro
009	Expansión del pecho
010	Rotación con flexión y presión hacia adelante y atrás
011	Flexión del codo y toque
012	Entrenamiento de toque del hombro
013	Extensión del tobillo y rotación interna y externa de la rodilla
014	Flexión y extensión de la rodilla (excluido)
015	Flexión y extensión de la cadera

2.2 Sensores y canales

Sensor	Ubicación
S1	Antebrazo afectado, aproximadamente 10 cm arriba del pliegue dorsal de la muñeca
S2	Brazo afectado, aproximadamente 8 cm arriba del epicóndilo lateral del húmero
S3	Parte inferior de la pierna afectada, entre 10 y 20 cm debajo de la rótula
S4	Muslo afectado, sobre la región del recto femoral
S5	Mano afectada; guante instrumentado

Los archivos *_1.npy contienen seis canales angulares (pitch1, yaw1, roll1, pitch2, yaw2 y roll2), mientras que *_2.npy contiene los cinco ángulos de flexión de los dedos y pitch3. Cada archivo tiene forma (número de muestras, longitud temporal, canales); en este conjunto la longitud temporal es 880 y existen seis canales por archivo.

Canal	Interpretación
pitch1 / pitch2	Rotación alrededor de X: inclinación hacia arriba o abajo
yaw1 / yaw2	Rotación alrededor de Z: giro hacia izquierda o derecha
roll1 / roll2	Rotación alrededor de Y: inclinación o balanceo longitudinal
f1	Flexión del pulgar
f2	Flexión del índice
f3	Flexión del dedo medio
f4	Flexión del anular
f5	Flexión del meñique
pitch3	Inclinación de la muñeca/mano registrada por la IMU del guante

2.3 Características extraídas

De cada señal se calcularon diez descriptores: media, desviación estándar, mediana, mínimo, máximo, rango, rango intercuartílico, RMS, energía y media del cambio absoluto entre instantes consecutivos (mad_diff). La combinación de 12 canales y 10 estadísticas produjo inicialmente 120 características.

Para el conjunto reducido se conservaron std, median, min, max, iqr y mad_diff. Se excluyó mean porque las señales ya estaban centradas y sus medias eran numéricamente cero; range se derivaba exactamente de max-min, y rms y energy duplicaban la información de std al cumplirse $RMS \approx std$ y $energy = 880 \cdot RMS^2$. Así, el EDA se realizó con 72 características complementarias.

3. Panorama general y calidad de datos

El conjunto reducido contiene 4,257 muestras, 72 características numéricas y 15 movimientos. No presenta valores faltantes. La clase más numerosa es 007 con 385 muestras y la menos numerosa es 001 con 212, para una razón de desbalance de 1.82:1; el desbalance es moderado y deberá considerarse mediante particiones estratificadas y métricas macro durante el modelado.




Figura 1. Distribución del número de muestras entre los 15 movimientos.

La revisión detectó además 68 filas con las 72 características iguales a cero, compartidas por diez movimientos. Estas observaciones son compatibles con registros completamente rellenos con ceros; se documentan como riesgo de calidad, pero su eliminación corresponde a la etapa posterior de limpieza. También se observaron duplicados adicionales, cuya interpretación debe contrastarse con el identificador de repetición antes del modelado.

4. Análisis univariado

Las distribuciones no son normales en términos generales. Las medidas de amplitud y cambio temporal presentan asimetría positiva y colas largas, mientras que los mínimos presentan asimetría negativa. La mediana es el descriptor más cercano a una forma simétrica (asimetría media 0.47), aunque exhibe numerosos valores señalados como atípicos por IQR debido a la mezcla de movimientos con posiciones centrales distintas.




Figura 2. Histogramas de la desviación estándar para los doce canales.

La desviación estándar evidencia heterogeneidad entre canales. pitch1 y pitch2 presentan distribuciones amplias y con indicios de varios grupos, mientras yaw, roll y los canales del guante se concentran más cerca de valores bajos y conservan colas derechas. pitch3 destaca por la mayor escala y dispersión, lo que sugiere variaciones importantes en la inclinación de la mano entre ejercicios.




Figura 3. Distribuciones de la mediana para los doce canales.

Las medianas de los canales angulares se concentran cerca de cero, coherente con el centrado de las señales, pero mantienen dispersión suficiente para distinguir posiciones predominantes. pitch3 y algunos canales de pitch muestran mayor amplitud; las medianas de los dedos se concentran en intervalos más estrechos.




Figura 4. Distribuciones de mad_diff para los doce canales.

mad_diff es marcadamente asimétrica y concentra muchas observaciones en cambios pequeños, con colas asociadas a ejecuciones más rápidas o abruptas. Esta propiedad temporal resulta después la más informativa: pitch1_mad_diff ocupa el primer lugar de información mutua y pitch2_mad_diff el tercero.




Figura 5. Comparación global de mad_diff por canal, sin mostrar valores extremos.

La comparación de cajas confirma que pitch3 posee la mayor variación temporal global. Entre los sensores corporales, roll1 y yaw1 muestran cambios relativamente altos; los dedos presentan

magnitudes menores, aunque esto no implica poca utilidad discriminante porque operan en una escala distinta.

El criterio IQR marcó como atípicas especialmente yaw2_median (21.7%), roll2_median (19.6%) y yaw1_median (16.1%). Estos puntos no deben eliminarse automáticamente: al mezclar 15 ejercicios, valores alejados de la distribución global pueden constituir justamente la señal que diferencia una clase.

5. Análisis multivariado y correlaciones




Figura 6. Matriz de correlación de Spearman entre las 72 características.

La matriz presenta bloques claros dentro de cada canal y entre dedos contiguos. Las asociaciones más altas vinculan std con máximos, mínimos, IQR o mad_diff del mismo canal: roll2_std–roll2_max ($\rho=0.951$), yaw1_std–yaw1_min ($\rho=-0.949$), yaw2_std–yaw2_max ($\rho=0.948$) y roll1_std–roll1_iqr ($\rho=0.939$). Esto indica redundancia residual natural entre medidas de amplitud, pero no identidad matemática como la eliminada previamente.

También aparecen asociaciones fuertes entre dedos: f3_iqr–f4_iqr ($\rho=0.922$), f2_std–f3_std ($\rho=0.918$) y f3_std–f4_std ($\rho=0.911$). El patrón es biomecánicamente coherente con el movimiento coordinado de dedos vecinos y sugiere que el guante captura sinergias de agarre, no cinco señales completamente independientes.




Figura 7. Perfil promedio estandarizado de las 72 características por movimiento.

El mapa de calor muestra firmas multivariadas diferenciadas. El movimiento 005 (flexión y extensión de muñeca) sobresale por mad_diff elevado en varios dedos; 000 destaca por gran variabilidad en pitch2; 008 combina cambios altos en pitch1 y pitch2; 009 presenta dispersión elevada en yaw1; 013 y 015 exhiben extremos intensos en canales angulares, coherentes con movimientos de pierna, rodilla y cadera. En contraste, 004 y 007 mantienen niveles bajos en varias características de pitch1, lo que podría hacerlos más parecidos en ciertos ejes y exigir información complementaria de otros sensores.

6. Interacciones y capacidad de diferenciación




Figura 8. Veinte características con mayor información mutua respecto al movimiento.

Las variables más informativas son pitch1_mad_diff (1.014), yaw1_std (0.993), pitch2_mad_diff (0.955), yaw1_max (0.948) y yaw1_min (0.917). El predominio de mad_diff y de canales angulares del miembro superior indica que la velocidad local de cambio y la amplitud de rotación son más útiles que una única medida de posición. El guante también contribuye: f2_mad_diff ocupa el sexto lugar, y pitch3_std el séptimo.

Para estudiar interacciones se eligieron cuatro variables con información mutua alta y correlación menor a 0.75 entre las seleccionadas: pitch1_mad_diff, yaw1_std, f2_mad_diff y pitch3_std. Esto combina antebrazo, amplitud angular, flexión del índice e inclinación de la mano, evitando seleccionar únicamente versiones redundantes de la misma señal.

Interacciones entre características informativas




Figura 9. Pairplot de las cuatro características informativas y complementarias.

Ninguna variable separa por sí sola los 15 movimientos: existe traslape considerable en las diagonales. Sin embargo, los diagramas bidimensionales generan estructuras y regiones más diferenciadas, especialmente cuando una variable corporal se combina con `f2_mad_diff` o `pitch3_std`. Esto muestra que la clasificación dependerá de patrones conjuntos y no de umbrales univariados.




Figura 10. Seis interacciones por pares entre las características seleccionadas.

La validación exploratoria con un árbol pequeño confirma la complementariedad. Las variables individuales obtuvieron F1 macro entre 0.204 y 0.258; al combinar pares, el resultado aumentó a valores entre 0.325 y 0.398. El mayor incremento correspondió a pitch1_mad_diff + f2_mad_diff: F1 macro 0.398 frente a 0.224 y 0.204 por separado. La combinación vincula cambio angular del antebrazo y cambio de flexión del índice, dos fuentes prácticamente no correlacionadas ($\rho=-0.060$).

Par	F1 macro combinado	Mejor F1 individual
pitch1_mad_diff + yaw1_std	0.325	0.224
pitch1_mad_diff + f2_mad_diff	0.398	0.224
pitch1_mad_diff + pitch3_std	0.341	0.258
yaw1_std + f2_mad_diff	0.343	0.224
yaw1_std + pitch3_std	0.330	0.258
f2_mad_diff + pitch3_std	0.336	0.258

7. Conclusiones

- La reducción de 120 a 72 características elimina duplicidades matemáticas sin perder los componentes esenciales de amplitud, posición, dispersión robusta y dinámica temporal.
- Las distribuciones son asimétricas y presentan colas largas; por ello, la mediana, el IQR y la correlación de Spearman son apropiados para complementar medidas convencionales.
- `mad_diff` es especialmente valiosa: tres variables de este tipo aparecen entre las diez primeras por información mutua, lo que confirma que la rapidez de cambio ayuda a diferenciar ejercicios.
- Los sensores corporales y el guante son complementarios. El antebrazo y brazo dominan varias variables angulares, mientras `f2_mad_diff` y `pitch3` aportan información adicional sobre mano y muñeca.
- Las altas correlaciones se concentran dentro de cada canal y entre dedos vecinos; esto refleja amplitud común y coordinación biomecánica, pero también aconseja controlar multicolinealidad o usar selección de variables en el modelado.
- Las interacciones mejoran sustancialmente el F1 macro frente a características individuales. La mayor mejora observada combina `pitch1_mad_diff` con `f2_mad_diff`, apoyando el uso conjunto de sensores.
- El conjunto presenta desbalance moderado y 68 muestras completamente nulas con etiquetas diferentes. Antes del entrenamiento se requiere una etapa de limpieza y una estrategia de validación que evite que estos registros distorsionen el modelo.

En conjunto, los resultados respaldan la viabilidad de diferenciar los ejercicios, pero anticipan que la separación no dependerá de una sola variable. El desempeño deberá provenir de la combinación de dinámica temporal, amplitud angular y flexión de los dedos, con especial cuidado en la redundancia y en los registros nulos.